Jurnal Algoritma
E-ISSN: 2302-7339 | P-ISSN: 1412-3622
INSTITUT TEKNOLOGI GARUT

https://jurnal.itg.ac.id/index.php/algoritma
DOI: 10.33364/algoritma/v.22-2.3013

Peningkatan Akurasi Rekomendasi Film Menggunakan *Neural Collaborative Filtering* dengan Arsitektur *RecommenderNet*

Dimas Sukmana[1], Rangga Gelar Guntara[2*], Muhammad Rizki Nugraha[3]
[1,2,3]Bisnis Digital, Universitas Pendidikan Indonesia, Indonesia

***email:** ranggagelar@upi.edu

Info Artikel
Dikirim: 18 Oktober 2025
Diterima: 29 November 2025
Diterbitkan: 30 November 2025

Kata kunci:
Collaborative Filtering;
NDCG;
Neural Collaborative Filtering;
RecommenderNet;
Root Mean Squared Error.

ABSTRAK

Pesatnya pertumbuhan industri film dan pengguna platform streaming memunculkan tantangan *information overload*, di mana pengguna kesulitan menemukan film yang sesuai dengan preferensi mereka di tengah melimpahnya pilihan konten. Penelitian ini bertujuan mengembangkan model sistem rekomendasi film berbasis *Neural Collaborative Filtering* (NCF) dengan arsitektur *RecommenderNet* untuk meningkatkan akurasi prediksi dan relevansi rekomendasi personal. Model dievaluasi menggunakan metrik *Root Mean Square Error* (RMSE) untuk menilai akurasi prediksi rating, serta *Normalized Discounted Cumulative Gain* (NDCG@100) untuk mengukur kualitas dan urutan rekomendasi. Hasil menunjukkan bahwa model mencapai RMSE 0.1946 dan NDCG@100 sebesar 0.8136, yang mengindikasikan kemampuan model dalam mempelajari preferensi pengguna dan menghasilkan rekomendasi yang relevan serta terurut dengan baik. Penelitian ini berkontribusi pada pengembangan sistem rekomendasi yang lebih efektif dan personal dalam domain *streaming* digital, serta menawarkan pendekatan yang efisien untuk mengurangi dampak *information overload* dan meningkatkan pengalaman pengguna.

1. PENDAHULUAN

Information overload merupakan kondisi ketika jumlah informasi yang tersedia melebihi kapasitas kognitif manusia dalam memproses dan memilih informasi yang relevan [1]. Fenomena ini kini juga terjadi dalam industri hiburan digital, khususnya layanan *streaming* film, seiring dengan meningkatnya volume konten yang tersedia [2]. Laporan WIPO&OMDIA menunjukkan bahwa produksi film global mencapai titik tertinggi pada tahun 2023 dengan total 9.511 judul, melampaui tingkat produksi sebelum pandemi [3]. Lonjakan ini, ditambah dengan pertumbuhan pesat pengguna platform streaming, memperkuat tantangan bagi pengguna dalam menemukan konten yang sesuai dengan preferensi mereka.

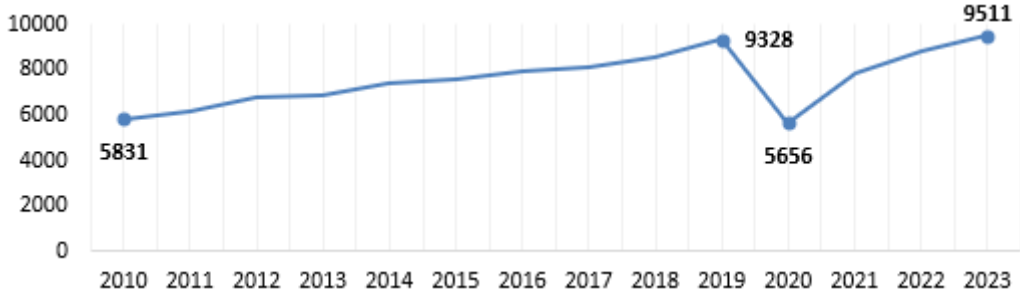

Gambar 1. Produksi film secara global dari tahun ke tahun

FlixPatrol melaporkan data pengguna Netflix sebagai salah satu platform *video-on-demand* terbesar mengalami pertumbuhan pelanggan yang signifikan dalam 6 tahun terakhir [4]. Gambar 2 menunjukkan bahwa jumlah pelanggan Netflix terus meningkat dari sekitar 139 juta pada tahun 2018 menjadi 301 juta pada tahun 2024. Peningkatan jumlah produksi film dan pertumbuhan pesat pengguna platform *streaming*, memunculkan permasalahan baru. Ribuan judul baru menambah katalog konten di berbagai platform *streaming* [5]. Akibatnya, pengguna dihadapkan pada ribuan konten yang terus bertambah setiap harinya [5].

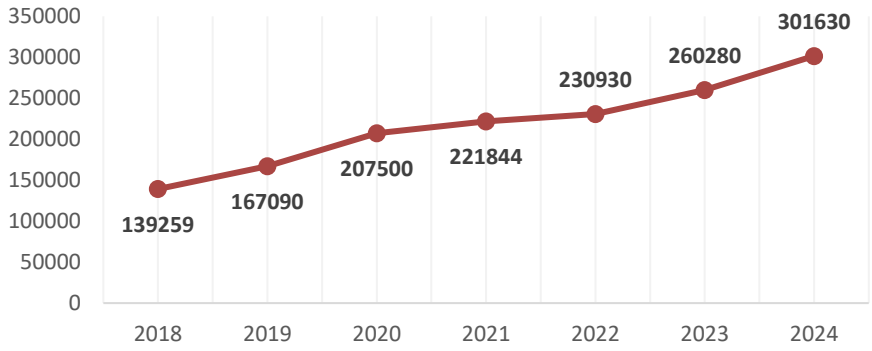

Gambar 2. Pengguna Netflix 6 tahun terakhir (dalam juta)

Sifat alami manusia yang cenderung ragu-ragu ketika dihadapkan pada banyak pilihan dapat menyebabkan mereka tidak memilih sama sekali atau membuat keputusan yang kurang tepat [6]. Fenomena ini sangat relevan pada platform *streaming* film seperti Netflix, di mana pengguna cenderung kehilangan minat setelah 60 hingga 90 detik mencari hingga 20 judul film [7]. Kondisi ini pada akhirnya menyebabkan ketidakpuasan pelanggan dan berujung pada hilangnya pengguna [7]. Ketersediaan konten dalam jumlah masif ini menciptakan kebingungan bagi pengguna dalam menemukan film yang benar-benar relevan dengan preferensi pribadi mereka [5]. Melihat permasalahan tersebut, preferensi pengguna menjadi elemen krusial dalam strategi bisnis modern terutama untuk mempertahankan loyalitas konsumen [8]. Penyesuaian konten berdasarkan minat individu tidak hanya meningkatkan kepuasan pengguna, tetapi juga memberikan dampak signifikan terhadap retensi pelanggan dan performa penjualan [9]. Oleh karena itu, pentingnya personalisasi layanan menjadikan sistem rekomendasi sebagai fitur yang sangat krusial dalam memengaruhi keputusan pengguna dalam menggunakan layanan yang diberikan [10]. Implementasi sistem rekomendasi yang dipersonalisasi telah terbukti efektif dalam memperkuat loyalitas pengguna serta mengoptimalkan pencapaian bisnis [9]. Dalam platform *streaming* seperti Netflix dan Disney+, sistem rekomendasi telah memainkan peran vital dalam meningkatkan pengalaman pengguna dan mempertahankan loyalitas pelanggan [11]. Menurut laporan dari Business Insider, sekitar 80% tayangan yang ditonton di Netflix berasal dari sistem rekomendasi, dan tanpa sistem tersebut, perusahaan diperkirakan dapat kehilangan hingga $1 miliar per tahun akibat rendahnya personalisasi layanan [12]. Dengan demikian, sistem rekomendasi memiliki peranan yang sangat penting dalam melakukan personalisasi layanan terhadap preferensi pengguna.

Secara umum, terdapat empat jenis sistem rekomendasi: *content-based*, *collaborative*, *context-aware*, dan *hybrid filtering* [10]. Dari keempatnya, *Collaborative Filtering* (CF) adalah salah satu pendekatan paling populer karena memberikan rekomendasi berdasarkan data historis pengguna [7]. *Collaborative Filtering* terdiri dari dua metode utama: *memory-based* dan *model-based* [7]. Namun, metode *memory-based*, yang mencakup teknik *user-based* dan *item-based*, masih tergolong sebagai sistem rekomendasi klasik yang mengabaikan interaksi kompleks antara pengguna dan produk atau layanan yang disajikan [10]. Penelitian [13], menunjukkan meskipun *Collaborative Filtering* (CF) klasik umum digunakan, pendekatan ini masih rentan terhadap masalah *data sparsity* dan *cold-start* saat diterapkan pada sistem rekomendasi film. Masalah *data sparsity* terjadi karena kurangnya interaksi atau data historis dari pengguna [14]. Sementara itu, *cold-start* muncul saat pengguna baru atau item baru masuk ke sistem, di mana belum ada data interaksi yang cukup untuk menghasilkan rekomendasi yang relevan [14]. Keterbatasan pada metode *Collaborative Filtering* klasik, seperti masalah *data sparsity* dan *cold-start*, menuntut adanya pendekatan yang lebih adaptif terhadap kompleksitas data pengguna modern. Seiring meningkatnya volume data dan keragaman perilaku pengguna di

era *information overload*, sistem rekomendasi perlu mampu memahami hubungan yang lebih dinamis dan personal. Oleh karena itu, seiring dengan pesatnya perkembangan teknologi *deep learning*, pendekatan berbasis *Neural Collaborative Filtering* (NCF) mulai dikembangkan sebagai solusi untuk mengatasi keterbatasan metode klasik [15]. NCF menggabungkan kekuatan *neural networks* dengan algoritma *Collaborative Filtering* untuk memodelkan interaksi non-linear antara pengguna dan item [15]. Arsitektur dari NCF secara umum dapat dilihat pada Gambar 3 berikut.

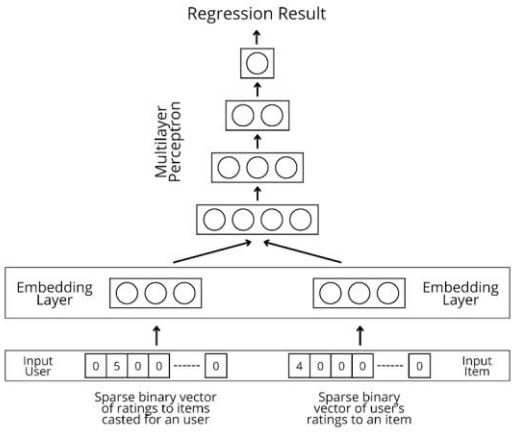

Gambar 3. Arsitektur NCF

Berdasarkan Gambar 3 arsitektur NCF memanfaatkan jaringan saraf tiruan, sehingga mampu merepresentasikan relasi non-linear antara interaksi pengguna dan item, sebuah kemampuan yang sulit dicapai oleh metode tradisional [16]. Meskipun demikian, arsitektur NCF yang ada masih sering mengandalkan pendekatan klasifikasi atau regresi umum. Pendekatan ini memiliki performa yang lebih baik dari pendekatan tradisional, namun rekomendasi yang diberikan belum bisa dikatakan relevan dengan preferensi pengguna [17]. Penelitian [18] menggunakan NCF dengan dataset MovieLens untuk sistem rekomendasi film berhasil memperoleh nilai RMSE sebesar 0.91467. Dari nilai RMSE yang dihasilkan penelitian tersebut, menunjukkan pendekatan tersebut belum bisa menghasilkan performa rekomendasi yang baik. Beberapa penelitian sebelumnya juga masih menggunakan dimensi embedding yang relatif kecil sehingga representasi hubungan laten antara pengguna dan film belum optimal dalam menangkap pola preferensi kompleks. Secara arsitektural, NCF konvensional juga belum sepenuhnya mampu memodelkan hubungan non-linear yang lebih dalam karena struktur representasi yang masih terbatas.

Untuk menjawab tantangan tersebut, arsitektur *RecommenderNet* dipertimbangkan sebagai pendekatan yang lebih unggul karena menggunakan mekanisme *embedding* yang lebih fleksibel, operasi *dot product* untuk pemodelan interaksi laten, serta fungsi aktivasi non-linear yang memungkinkan representasi preferensi pengguna dipelajari secara lebih komprehensif. Dengan desain modular dan dukungan implementasi dari TensorFlow/Keras, *RecommenderNet* menawarkan tingkat efisiensi pelatihan, skalabilitas model, serta performa prediksi yang lebih baik dibandingkan arsitektur NCF konvensional [19]. Penelitian [20] menunjukkan bahwa penerapan arsitektur *RecommenderNet* dapat menghasilkan performa yang unggul dengan nilai RMSE sebesar 0.2579 dalam konteks sistem rekomendasi pariwisata. Hal ini membuktikan bahwa *RecommenderNet* berpotensi menghasilkan sistem rekomendasi dengan akurasi yang lebih baik.

Berdasarkan kondisi tersebut, penelitian ini mengusulkan pengembangan model *Neural Collaborative Filtering* dengan arsitektur *RecommenderNet* yang dikembangkan oleh Keras sebagai implementasi modular dan efisien dari pendekatan NCF untuk sistem rekomendasi film. Arsitektur ini menggunakan *embedding layer* untuk merepresentasikan pengguna dan film secara lebih komprehensif, serta *bias layer* dan operasi *dot product* untuk menangkap interaksi laten dengan presisi tinggi [19]. Perancangan NCF dengan arsitektur *RecommenderNet* dipilih agar dapat menganalisis pola preferensi pengguna dan menyediakan rekomendasi yang relevan [20]. Kombinasi ini diharapkan dapat meningkatkan performa dan kualitas hasil rekomendasi film yang relevan, serta mampu mengatasi permasalahan *information overload* dan dapat meningkatkan

pengalaman pengguna. Perancangan model ini memanfaatkan tahap preprocessing untuk menormalisasi skala rating, agar model menjadi lebih mudah untuk mempelajari data saat training. Selanjutnya, model NCF dengan arsitektur *RecommenderNet* di susun untuk dapat memperhitungkan interaksi *user* dan film beserta masing masing bobotnya. Kemudian, model di training sekaligus dilakukan evaluasi pada data validasi dengan metrik RMSE untuk melihat kualitas model sistem rekomendasi yang dihasilkan. Dengan skema tersebut, penelitian ini diharapkan mampu untuk mengatasi permasalahan *information overload* dengan cara mempersonalisasi preferensi pribadi dari pengguna layanan platform *streaming* film.

2. METODE PENELITIAN

Dataset yang digunakan dalam penelitian ini diperoleh dari platform Kaggle dengan judul *Movie Recommendation Data* yang di publish oleh Rohan Sharma sebagai authornya. Seluruh tahapan pengolahan data dan pengembangan model dilakukan menggunakan Google Colab sebagai IDE (*Integrated Development Environment*) utama [21]. Gambaran umum dari penelitian ini dapat dilihat pada Gambar 4 berikut.

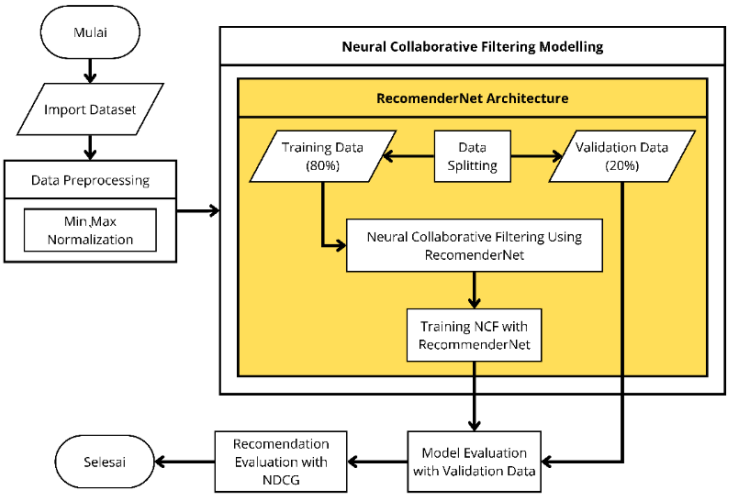

Gambar 4. Gambaran Umum Penelitian

Berdasarkan Gambar 4, penelitian ini memiliki beberapa tahapan pada perancangan sistem rekomendasi film menggunakan arsitektur *RecommenderNet*. Tahapan utama penelitian ini adalah mengimport data dari dataset *movies* dan dataset *ratings*, menormalisasi data rating, membagi data *training* dan *validation*, merancang model NCF dengan arsitektur *RecommenderNet*, melatih model dengan data training, melakukan evaluasi model dengan data validasi menggunakan metrik RMSE untuk memastikan tidak terjadinya *overfitting* pada model, terakhir menghitung kualitas rekomendasi film yang diberikan model dengan NDCG@k.

2.1. Dataset

Penelitian ini menggunakan data yang terdiri atas empat file utama, yaitu links.csv, movies.csv, ratings.csv, dan tags.csv. Dari keseluruhan file tersebut, fokus utama penelitian berada pada file ratings.csv yang memuat data interaksi eksplisit berupa rating dari pengguna terhadap film, serta movies.csv yang berisi informasi judul dan genre film. Ringkasan dataset ratings.csv dan movies.csv diperlihatkan pada Tabel 1 dan Tabel 2.

Tabel 1. Dataset Ratings

No.	userId	movieId	rating	timestamp
0	1	1	4.0	964982703
1	1	3	4.0	964981247
2	1	6	4.0	964982224
...	...	...	...	...

No.	userId	movieId	rating	timestamp
100835	610	170875	3.0	1493846415

Berdasarkan Tabel 1, dataset ratings.csv mencakup 100835 entri, dengan rating bernilai antara 0.5 hingga 5.0. Dataset ini berisi interaksi pengguna dengan film yang di ringkas dalam kolom id pengguna, id film, rating yang diberikan beserta timestamp.

Tabel 2. Dataset Film

No.	movieId	title	genres
0	1	Toy Story (1995)	Adventure|Animation|Children|Comedy|Fantasy
1	2	Jumanji (1995)	Adventure|Children|Fantasy
2	3	Grumpier Old Men (1995)	Comedy|Romance
...	...	...	...
9741	193609	Andrew Dice Clay: Dice Rules (1991)	Comedy

Tabel 2 menjelaskan dataset movies.csv memuat informasi tentang 9.742 entri film, dan kolom kakteristik film yang meliputi movieId, title, dan genres.

2.2. Data Pre-processing

Tahap prapemrosesan data dilakukan untuk memastikan kualitas dan konsistensi dataset sebelum proses pelatihan model. Langkah pertama adalah pemeriksaan dan penanganan data hilang pada file *ratings.csv* dan *movies.csv*. Data yang mengandung *missing value* dihapus karena proporsinya sangat kecil dan tidak memengaruhi distribusi keseluruhan. Selanjutnya, kolom userId dan movieId pada *ratings.csv* di-*encode* menjadi indeks numerik berurutan agar dapat diproses oleh *embedding layer* pada *RecommenderNet*. Hasil *encoding* kemudian di-*mapping* kembali ke dataset untuk memastikan kesesuaian antara pengguna dan film pada seluruh entri. Setelah itu, dataset di-*shuffle* untuk menghindari bias urutan data saat pelatihan. Kolom rating kemudian dinormalisasi menggunakan metode Min–Max Scaling agar seluruh nilai berada pada rentang [0,1][0,1][0,1]. Normalisasi ini penting untuk mempercepat proses konvergensi selama *training* dan menjaga kesetaraan skala antarfitur. Persamaan umum Min–Max Scaling ditunjukkan pada Persamaan (1):

$$\acute{x} = \frac{x - min(x)}{max(x) - min(x)} \quad (1)$$

Keterangan:
$\acute{x}$: Rating yang dinormalisasi
x : Rating
$min(x)$: Rating terkecil
$max(x)$: Rating terbesar

Tahap terakhir adalah pembagian dataset menjadi 80 % *training data* dan 20 % *validation data* secara acak [20]. Pembagian ini memastikan model mendapatkan proporsi data yang seimbang dan memastikan tidak terjadinya *overfitting* pada model [22]. Seluruh proses prapemrosesan dilakukan di Google Colab menggunakan bahasa pemrograman Python serta pustaka *pandas* dan *scikit-learn* untuk operasi *encoding*, normalisasi, dan pembagian data. Dataset yang telah melalui tahap prapemrosesan selanjutnya digunakan untuk pelatihan model NCF dengan arsitektur *RecommenderNet*.

2.3. *Neural Collaborative Filtering* with *RecommenderNet*

Neural Collaborative Filtering merupakan metode yang paling merepresentasikan penggunaan deep learning dalam penerapan sistem rekomendasi [23]. Model sistem rekomendasi pada penelitian ini dikembangkan menggunakan pendekatan *Neural Collaborative Filtering* (NCF) dengan arsitektur *RecommenderNet* berbasis *TensorFlow/Keras*. RecommenderNet dipilih karena memiliki desain modular yang lebih efisien dan stabil

dibandingkan NCF konvensional, serta mampu mempelajari hubungan non-linear antara pengguna dan item melalui representasi *embedding* yang komprehensif [19]. Berbeda dengan metode *Matrix Factorization* yang bersifat linear dan terbatas dalam menangkap interaksi kompleks, *RecommenderNet* mampu melakukan generalisasi yang lebih baik terhadap pola perilaku pengguna yang bervariasi [24]. Arsitektur *RecommenderNet* diilustrasikan secara visual pada Gambar 5 berikut.

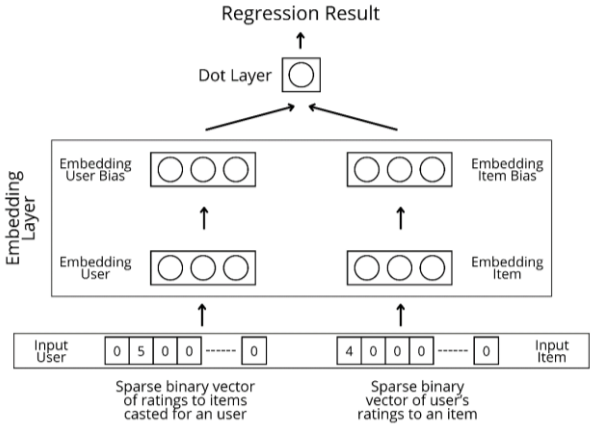

Gambar 5. Arsitektur *RecommenderNet*

Arsitektur model terdiri atas dua *embedding layer* untuk merepresentasikan pengguna dan film dalam bentuk vektor laten berdimensi tetap, serta dua bias layer untuk menangkap kecenderungan rating masing-masing entitas. Representasi vektor laten pengguna dan film digabungkan melalui operasi *dot product* untuk memodelkan tingkat kesesuaian antara keduanya, kemudian ditambahkan bias dan diproses menggunakan fungsi aktivasi sigmoid untuk menghasilkan prediksi rating dalam rentang 0–1 yang konsisten. Parameter pemodelan pada Tabel 3 dipilih secara metodologis untuk menyeimbangkan performa dan efisiensi model. Dimensi embedding sebesar 4 dipilih karena ukuran embedding yang lebih besar berpotensi meningkatkan kompleksitas model tanpa peningkatan signifikan terhadap akurasi pada dataset bersparsitas tinggi [24]. Penggunaan optimizer Adam dengan learning rate 0.001 dipilih karena kemampuannya mencapai konvergensi stabil pada dataset skala menengah [25]. Regularisasi L2 (1e-6) diterapkan untuk mengurangi risiko overfitting, sementara konfigurasi 15 epoch dan batch size 128 ditetapkan berdasarkan pengamatan kurva loss selama pelatihan, yang menunjukkan titik kestabilan model tanpa indikasi degradasi kinerja [22].

Tabel 3. Inisialisasi dan Konfigurasi Model *RecommenderNet*

Komponen	Parameter / Nilai
Dimensi *Embedding*	4
Inisialisasi Bobot	he_normal
Regularisasi	L2 (1e-6)
Fungsi Aktivasi Output	Sigmoid (tf.nn.sigmoid)
Fungsi *Loss*	*Binary crossentropy*
Optimizer	Adam (learning rate = 0.001)
Metrik Evaluasi	*Root mean squared error* (RMSE)
*Epoch*s	15
Batch size	128

2.4. Evaluasi Model

Tahap evaluasi dilakukan untuk menilai kinerja model *RecommenderNet* setelah proses pelatihan. Evaluasi difokuskan pada *Root mean squared error* (RMSE) karena metrik ini umum digunakan untuk mengukur akurasi prediksi pada sistem rekomendasi berbasis rating [13]. RMSE menghitung deviasi rata-rata kuadrat antara nilai rating sebenarnya (y_i) dan nilai prediksi model ($\hat{y}_i$) dengan rumus:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)} \quad (2)$$

Keterangan:
n : Jumlah item yang di rating oleh pengguna
$\hat{y}_i$: Rating prediksi
y_i : Rating sebenarnya

2.5. Evaluasi Rekomendasi

Selain menilai akurasi prediksi rating menggunakan RMSE, penelitian ini juga mengevaluasi kualitas urutan rekomendasi yang dihasilkan model *RecommenderNet* dengan metrik *Normalized Discounted Cumulative Gain* (NDCG@k). NDCG@k mengukur seberapa baik sistem menempatkan item yang paling relevan di posisi teratas dalam daftar rekomendasi dengan panjang k [26]. Metrik ini memperhitungkan relevansi dan posisi item, sehingga rekomendasi dengan relevansi tinggi yang muncul lebih awal mendapatkan bobot lebih besar. Perhitungan NDCG@k dilakukan dalam dua tahap. Pertama, dihitung *Discounted Cumulative Gain* (DCG@k):

$$DCG@k = \sum_{i=1}^{k} \frac{2^{rel_i - 1}}{\log_2(i+1)} \quad (3)$$

dengan (rel_i) adalah relevansi item pada posisi (i). Kedua, DCG@k dinormalisasi dengan Ideal DCG (IDCG@k), yaitu DCG dari urutan ideal:

$$NDCG@k = \frac{DCG@k}{IDCG@k} \quad (4)$$

Nilai NDCG@k berada pada rentang 0 hingga 1, di mana nilai mendekati 1 menandakan bahwa daftar rekomendasi model hampir sama baiknya dengan urutan ideal [27]. Pada penelitian ini, NDCG@100 digunakan sebagai standar pengujian, yang berarti sistem menilai kualitas seratus rekomendasi teratas untuk setiap pengguna. Evaluasi dilakukan pada data validasi yang terpisah dari data pelatihan. Nilai NDCG@100 dihitung untuk setiap pengguna, kemudian dirata-ratakan sebagai ukuran akhir performa sistem [26]. Pemilihan metrik NDCG@k penting karena mencerminkan pengalaman pengguna, di mana relevansi dan posisi rekomendasi sangat memengaruhi kepuasan terhadap sistem.

3. HASIL DAN PEMBAHASAN

3.1 *Import* Dataset

Proses pengolahan dimulai dengan mengimpor dataset *Movie Recommendation Data* yang diperoleh dari platform Kaggle. Dataset ini terdiri atas empat berkas utama, yaitu *ratings.csv*, *movies.csv*, *links.csv*, dan *tags.csv*. Namun penelitian ini berfokus pada berkas *ratings.csv* dan *movies.csv* karena memuat informasi interaksi eksplisit pengguna terhadap film beserta metadata film. Hasil pembacaan menunjukkan bahwa berkas *ratings.csv* memuat 100.836 baris data dengan empat kolom utama: *userId*, *movieId*, *rating*, dan *timestamp*. Sementara itu, berkas *movies.csv* memuat 9.742 baris yang mencakup *movieId*, *title*, dan *genres*. Keberhasilan proses *import dataset* ini menjadi tahap awal penting sebelum dilakukan prapemrosesan data dan pembangunan model. Data yang telah dimuat selanjutnya digunakan pada tahap *data preprocessing* untuk pembersihan, normalisasi, dan pembagian menjadi data pelatihan dan validasi.

3.2 *Data Preprocessing*

Tahap *preprocessing* dilakukan dengan tujuan meningkatkan kualitas data sebagai *input* model dan meminimalkan *noise* yang berpotensi mengganggu proses pelatihan. Langkah pertama adalah memeriksa struktur dan kualitas data dengan fungsi *info()* dan *isnull().sum()* guna mendeteksi nilai kosong atau duplikat.

Hasil pengecekan menunjukkan bahwa berkas utama *ratings.csv* dan *movies.csv* tidak memiliki *missing value* sehingga dapat digunakan langsung tanpa imputasi. Selanjutnya, kolom userId dan movieId pada *ratings.csv* di-*encode* menjadi indeks numerik berurutan melalui proses *dictionary mapping* (*user_to_user_encoded* dan *movies_to_movies_encoded*). Proses *encoding* ini penting agar setiap pengguna dan film memiliki representasi integer unik yang kompatibel dengan *embedding layer* pada arsitektur *RecommenderNet*. Hasil encoding kemudian ditambahkan sebagai kolom baru *user* dan movie untuk menjaga keterhubungan data. Setelah proses encoding, dataset diacak menggunakan sample(*frac=1*, *random_state=42*) untuk mencegah bias urutan data selama pelatihan. Tahap berikutnya adalah normalisasi nilai *rating* dari rentang asli 0.5–5.0 menjadi [0,1] menggunakan metode *Min–Max Scaling*. Proses normalisasi *rating* menghasilkan output sebagaimana ditunjukkan pada Tabel 4.

Tabel 4. Normalisasi Rating

No.	ratings	normalized_ratings
0	4.5	0.888889
1	3.0	0.555556
2	3.0	0.555556
...	...	...
100835	5.0	1.000000

Rating dinormalisasi untuk memudahkan model dalam proses optimasi, menjaga kesetaraan skala antarfitur dan mempercepat proses konvergensi model. Terakhir, dataset dibagi menjadi 80 % data latih dan 20 % data validasi. Variabel input berupa pasangan ID pengguna dan film, sedangkan target adalah nilai rating yang telah dinormalisasi. Seluruh proses prapemrosesan dilakukan di lingkungan Google Colab menggunakan pustaka Python seperti *pandas*, *NumPy*, dan *scikit-learn*, menghasilkan dataset yang bersih, ter-*encode*, dan siap digunakan untuk melatih model NCF berbasis *RecommenderNet*.

3.3 *Neural Collaborative Filtering with RecommenderNet*

Model sistem rekomendasi dibangun dengan pendekatan *Neural Collaborative Filtering* menggunakan arsitektur *RecommenderNet* pada framework TensorFlow/Keras [20]. Arsitektur terdiri dari *embedding* pengguna dan *embedding* film berdimensi 4, nilai yang dipilih berdasarkan keseimbangan antara kompleksitas model dan risiko *overfitting* pada dataset yang relatif padat tetapi bersifat *sparse* pada level pengguna tertentu [24]. Semua *layer* menggunakan inisialisasi bobot he_normal dan regularisasi L2 (1e-6) guna mencegah *overfitting* [22]. Hasil vektor pengguna dan film digabung melalui operasi dot layer dan ditambahkan dengan bias, kemudian diproses dengan fungsi aktivasi sigmoid untuk menghasilkan prediksi rating dalam rentang 0-1 [25]. Ringkasan pemodelan NCF menggunakan arsitektur *RecommenderNet* ditunjukkan pada Gambar 6.

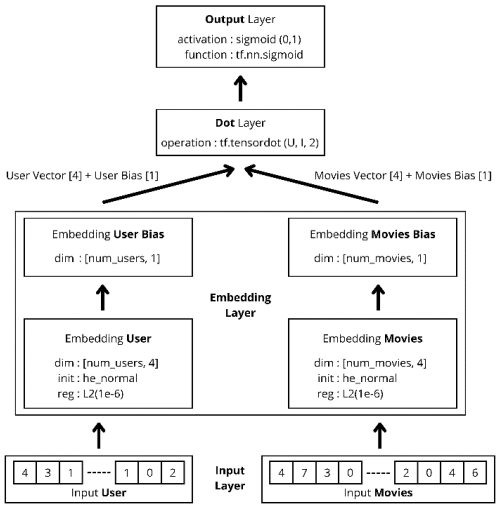

Gambar 6. Ringkasan Pemodelan NCF dengan arsitektur *RecommenderNet*

Model dikompilasi dengan *Binary crossentropy* sebagai fungsi kerugian, Adam (lr=0.001) sebagai *optimizer* untuk mencegah overfitting dan mempercepat proses pembelajaran, serta metrik evaluasi RMSE untuk memantau akurasi prediksi. Pelatihan dilakukan menggunakan data latih (80%) dan data validasi (20%). Model dilatih selama 15 *epoch* dengan *batch_size* 128, konfigurasi yang secara empiris memberikan stabilitas konvergensi tanpa memerlukan waktu komputasi yang berlebihan. Proses ini menghasilkan penurunan *loss* dan RMSE yang konsisten, menandakan bahwa *RecommenderNet* mampu mempelajari pola interaksi laten antara pengguna dan film.

3.4 *Model Evaluation*

Selama pelatihan, fungsi *loss Binary crossentropy* digunakan karena nilai rating telah dinormalisasi dalam rentang 0–1, sementara metrik *Root mean squared error* (RMSE) dipantau untuk menilai stabilitas dan konvergensi model [20]. Hasil pelatihan ditunjukkan pada Gambar 7 (a), di mana grafik *learning curve* pada Gambar 7 (a) menunjukkan bahwa RMSE pada data latih dan validasi menurun secara konsisten hingga mencapai titik konvergensi sekitar *epoch* ke-12, di mana tidak terjadi peningkatan signifikan setelahnya. Hasil pelatihan menunjukkan bahwa model memperoleh RMSE 0.1815 pada data latih dan 0.1946 pada data validasi, dengan selisih yang kecil, menandakan bahwa model mampu melakukan generalisasi dengan baik tanpa mengalami *overfitting*.

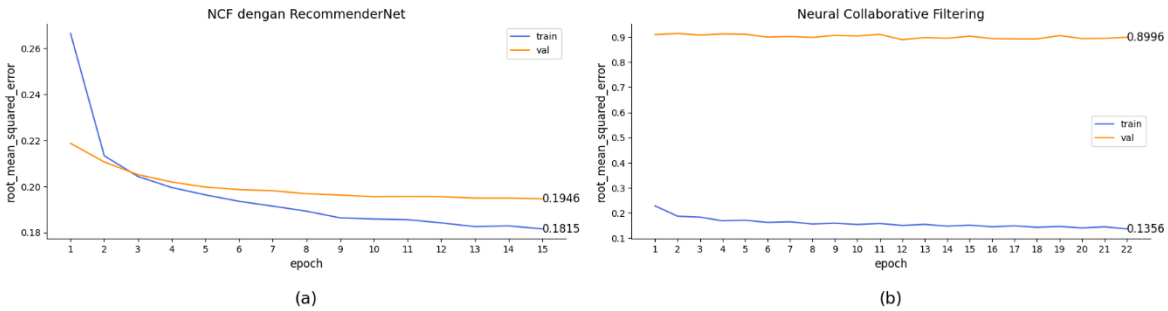

Gambar 7. Perbandingan hasil evaluasi model dengan metrik RMSE antara (a) *Neural Collaborative Filtering* (NCF) dengan arsitektur *RecommenderNet* (Penelitian Saat Ini) dan (b) NCF konvensional berdasarkan penelitian [18]

Model *RecommenderNet* pada penelitian ini menunjukkan performa yang lebih stabil dan *generalizable*, dengan selisih kecil antara data latih dan validasi serta nilai *RMSE* yang jauh lebih rendah. Keberhasilan ini berasal dari penggunaan *embedding layer* untuk merepresentasikan relasi laten antara pengguna dan film secara lebih mendalam [24], serta kombinasi fungsi aktivasi *sigmoid*, *regularisasi L2*, dan *optimizer Adam* yang membantu mempercepat konvergensi serta mencegah *overfitting* [20], [25]. Sebagai perbandingan, penelitian [18] yang menggunakan pendekatan *Neural Collaborative Filtering* (NCF) pada dataset MovieLens memperoleh hasil berbeda seperti ditunjukkan pada Gambar 7 (b), dengan *train loss* sebesar 0.1356 dan *validation loss* sebesar 0.8896. Perbedaan nilai yang cukup besar antara *train loss* dan *validation loss* tersebut menunjukkan potensi *overfitting* yang signifikan. Hal ini memperkuat kontribusi *RecommenderNet* dalam menciptakan model yang lebih stabil dan akurat.

3.5 *Recommendation Evaluation*

Evaluasi kualitas rekomendasi dalam penelitian ini menggunakan metrik *Normalized Discounted Cumulative Gain* (NDCG@k), yang banyak digunakan dalam penelitian sistem rekomendasi karena kemampuannya mengukur relevansi sekaligus posisi peringkat item dalam daftar rekomendasi [24, 25, 26, 27]. Analisis awal terhadap riwayat rating pengguna 474 pada pada Tabel 5 menunjukkan kecenderungan pada genre drama dan thriller, yang menjadi dasar model dalam menghasilkan rekomendasi personal.

Tabel 5. Film dengan rating tertinggi (*user* 474)

title	genres	ratings
Sense and Sensibility (1995)	Drama|Romance	5.0
Prince of Egypt, The (1998)	Animation|Musical	5.0
King and I, The (1956)	Drama|Musical|Romance	5.0
Mission, The (1986)	Drama	5.0

Berdasarkan pola tersebut, model *RecommenderNet* menghasilkan 100 rekomendasi film teratas yang dianggap paling relevan. Beberapa film hasil rekomendasi tersebut ditunjukkan pada Tabel 6 sebagai representasi output model untuk pengguna 474.

Tabel 6. Output 100 Rekomendasi Film untuk *user* 474

no	Id	title	genres
0	175	Kids (1995)	Drama
1	290	Once Were Warriors (1994)	Crime|Drama
2	800	Lone Star (1996)	Drama|Mystery|Western
...	...	...	...
99	180031	The Shape of Water (2017)	Adventure|Drama|Fantasy

Evaluasi menggunakan metrik NDCG@100 dilakukan berdasarkan daftar rekomendasi yang dihasilkan model untuk menilai relevansi film terhadap preferensi pengguna. Hasil evaluasi menunjukkan nilai NDCG@100 sebesar 0.8136, menandakan bahwa model mampu menempatkan film relevan di posisi atas dengan urutan mendekati ideal. Visualisasi hasil evaluasi disajikan pada Gambar 8, distribusi skor relevansi yang menurun secara bertahap, menunjukkan kemampuan model dalam mengenali preferensi pengguna dan memprioritaskan film yang paling sesuai. Keunggulan ini menegaskan efektivitas *RecommenderNet* dalam mempelajari pola interaksi pengguna terhadap film melalui representasi *embedding* dan aktivasi *sigmoid* [19]. Secara praktis, hasil ini menunjukkan potensi penerapan model untuk meningkatkan personalisasi konten dan pengalaman pengguna pada platform *streaming* digital.

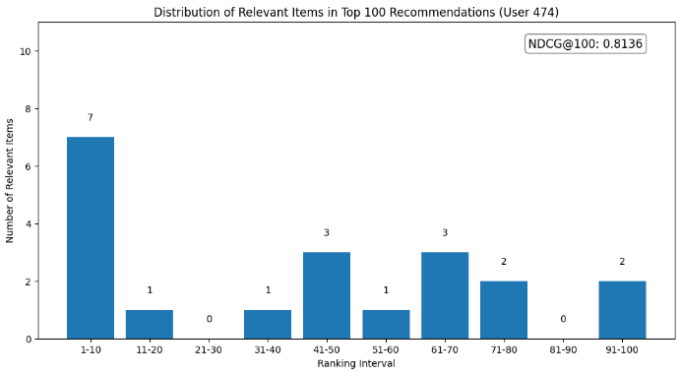

Gambar 8. Evaluasi NDCG dan Distribusi Item Relevan pada Peringkat Rekomendasi

4. KESIMPULAN

Implementasi *Neural Collaborative Filtering* (NCF) dengan arsitektur *RecommenderNet* dalam penelitian ini berhasil menunjukkan peningkatan performa model sistem rekomendasi film. Model mencapai nilai RMSE sebesar 0.1946 dan NDCG@100 sebesar 0.8136, yang mengindikasikan akurasi prediksi dan relevansi rekomendasi yang tinggi. Keberhasilan ini didorong oleh beberapa elemen kunci, yaitu penerapan normalisasi rating yang meningkatkan stabilitas proses pelatihan, penggunaan regularisasi L2 yang efektif mencegah *overfitting*, serta desain arsitektur *RecommenderNet* yang ringan, modular, dan efisien, memungkinkan pemodelan interaksi non-linear laten antara pengguna dan film melalui *embedding layer* dan fungsi aktivasi

sigmoid. Penelitian ini memberikan kontribusi ilmiah dengan memperkuat bukti bahwa *RecommenderNet* mampu mengatasi keterbatasan NCF klasik, seperti *embedding* dimensi kecil dan performa yang kurang stabil pada dataset dengan *sparsity* tinggi. Selain itu, pendekatan ini menawarkan solusi terukur dan praktis bagi pengembang sistem rekomendasi pada platform *streaming* digital, yang membutuhkan model personalisasi yang efisien dan *scalable* dalam kondisi *information overload*. Namun, penelitian ini masih memiliki keterbatasan karena hanya memanfaatkan *explicit feedback* berupa rating, tanpa melibatkan *implicit feedback* seperti durasi tonton, frekuensi klik, atau interaksi perilaku pengguna lainnya. Penelitian lanjutan disarankan untuk mengintegrasikan *implicit feedback* serta fitur non-rating seperti genre, popularitas, dan konteks waktu guna memperkaya representasi preferensi pengguna. Selain itu, penerapan model pada lingkungan produksi nyata serta verifikasi melalui *user-side evaluation* diperlukan untuk memperoleh pemahaman lebih mendalam mengenai dampak model terhadap pengalaman pengguna dan performa bisnis. Kombinasi pendekatan *hybrid filtering* juga berpotensi menjadi arah pengembangan yang relevan untuk mengatasi kasus *cold-start* dan meningkatkan fleksibilitas terhadap dinamika perilaku pengguna.

REFERENSI

[1] T. Koltay, "'Taming' information overload," *Academia Letters*, Jan 2021, doi: 10.20935/AL272.

[2] D. Bawden dan L. Robinson, "Information Overload: An Introduction," *Oxford Research Encyclopedia of Politics*, Jun 2020, doi: 10.1093/ACREFORE/9780190228637.013.1360.

[3] David Hancock, Claire Rousseau, Jeff Slee, dan Sacha Wunsch-Vincent, "Global Film Production Hits Historic High, Surpassing Pre-Pandemic Levels." Diakses: 5 Oktober 2025. [Daring]. Tersedia pada: https://www.wipo.int/en/web/global-innovation-index/w/blogs/2025/global-film-production

[4] FlixPatrol, "Netflix Subscribers." Diakses: 5 Oktober 2025. [Daring]. Tersedia pada: https://flixpatrol.com/streaming-service/netflix/subscribers/

[5] L. Romero Meza dan G. D'Urso, "User's Dilemma: A Qualitative Study on the Influence of Netflix Recommender Systems on Choice Overload," *Psychol Stud (Mysore)*, vol. 69, no. 3, hlm. 349–367, Sep 2024, doi: 10.1007/s12646-024-00807-0.

[6] B. Schwartz, *The Paradox of Choice Why More Is Less*. New York: HarperCollins, 2007.

[7] U. Thakker, R. Patel, dan M. Shah, "A comprehensive analysis on movie recommendation system employing collaborative filtering," *Multimed Tools Appl*, vol. 80, no. 19, hlm. 28647–28672, Agu 2021, doi: 10.1007/s11042-021-10965-2.

[8] A. Al Masud, S. Ahmed, M. T. Kaisar, B. Hossain, M. Shimu, dan M. F. Islam, "Unveiling brand loyalty in emerging markets: Analyzing smartphone user preferences: Robustness of structural equation modeling (SEM) and simultaneous equation modeling (SEMs)," *Journal of Open Innovation: Technology, Market, and Complexity*, vol. 10, no. 3, hlm. 100353, Sep 2024, doi: 10.1016/J.JOITMC.2024.100353.

[9] D. Ati Mustikasari, R. Hurriyati, P. Dewi Dirgantari, M. Adieb Sultan, N. Susi Susilawati Sugiana, dan A. Mustikasari, "The Role of Artificial Intelligence in Brand Experience: Shaping Consumer Behavior and Driving Repurchase Decisions The Role of Artificial Intelligence in Brand Experience: Shaping Consumer Behavior and Driving Repurchase Decisions," *Int J Adv Comput Sci Appl*, vol. 16, no. 4, hlm. 2025, 2025, doi: 10.14569/IJACSA.2025.0160432.

[10] S. Subhan, D. L. Syarif, E. Widhihastuti, S. K. Rakainsa, M. Sam'an, dan Y. N. Ifriza, "Improved recommender system using Neural Network Collaborative Filtering (NNCF) for E-commerce cosmetic product," *Sinergi (Indonesia)*, vol. 29, no. 1, hlm. 155–162, 2025, doi: 10.22441/sinergi.2025.1.014.

[11] Y. Ariyanto dan T. Widiyaningtyas, "A SYSTEMATIC REVIEW OF MOVIE RECOMMENDER SYSTEMS," *Journal of Engineering and Technology for Industrial Applications*, vol. 10, no. 47, hlm. 34–41, Jul 2024, doi: 10.5935/jetia.v10i47.1052.

[12] N. McAlone, "Netflix Recommendation Engine Worth $1 Billion Per Year - Business Insider." Diakses: 5 Oktober 2025. [Daring]. Tersedia pada: https://www.businessinsider.com/netflix-recommendation-engine-worth-1-billion-per-year-2016-6

[13] T. Anwar dan V. Uma, "Comparative study of recommender system approaches and movie recommendation using collaborative filtering," *International Journal of System Assurance Engineering and Management*, vol. 12, no. 3, hlm. 426–436, Jun 2021, doi: 10.1007/s13198-021-01087-x.

[14] T. Anwar, V. Uma, M. I. Hussain, dan M. Pantula, "Collaborative filtering and kNN based recommendation to overcome cold start and sparsity issues: A comparative analysis," *Multimed Tools Appl*, vol. 81, no. 25, hlm. 35693–35711, Okt 2022, doi: 10.1007/s11042-021-11883-z.

[15] H. Liu, "Implementation and Effectiveness Evaluation of Four Common Algorithms of Recommendation Systems-User Collaboration Filter, Item-based Collaborative Filtering, Matrix Factorization and Neural Collaborative Filtering," *Proceedings - 2022 International Conference on Cloud Computing, Big Data Applications and Software Engineering, CBASE 2022*, hlm. 224–227, 2022, doi: 10.1109/CBASE57816.2022.00049.

[16] V. Perifanis dan P. S. Efraimidis, "Federated Neural Collaborative Filtering," *Knowl Based Syst*, vol. 242, hlm. 108441, Apr 2022, doi: 10.1016/J.KNOSYS.2022.108441.

[17] J. Bobadilla, A. Gutiérrez, S. Alonso, dan Á. González-Prieto, "Neural Collaborative Filtering Classification Model to Obtain Prediction Reliabilities.," *International Journal of Interactive Multimedia and Artificial Intelligence*, vol. 7, no. 4, hlm. 18–26, Jun 2022, doi: 10.9781/IJIMAI.2021.08.010.

[18] N. K. Ayyiyah, R. Kusumaningrum, dan R. Rismiyati, "Film Recommender System Menggunakan Metode Neural Collaborative Filtering," *Jurnal Teknologi Informasi dan Ilmu Komputer*, vol. 10, no. 3, hlm. 699–708, Jul 2023, doi: 10.25126/jtiik.2023106616.

[19] S. Banerjee, "Collaborative Filtering for Movie Recommendations." Diakses: 5 Oktober 2025. [Daring]. Tersedia pada: https://keras.io/examples/structured_data/collaborative_filtering_movielens/

[20] K. E. Permana, A. B. Rahmat, D. A. Wicaksana, dan D. Ardianto, "Collaborative filtering-based Madura Island tourism recommendation system using RecommenderNet," dalam *BIO Web of Conferences*, EDP Sciences, Nov 2024. doi: 10.1051/bioconf/202414601080.

[21] R. G. Guntara, "Pemanfaatan Google Colab Untuk Aplikasi Pendeteksian Masker Wajah Menggunakan Algoritma Deep Learning YOLOv7," *Jurnal Teknologi Dan Sistem Informasi Bisnis*, vol. 5, no. 1, hlm. 55–60, Feb 2023, doi: 10.47233/JTEKSIS.V5I1.750.

[22] M. S. Azzahra, S. S. Maesaroh, dan R. G. Guntara, "Penggunaan Convolutional Neural Network dan Transfer Learning untuk Rekomendasi Gaya Rambut Pria," *Jurnal Algoritma*, vol. 21, no. 2, hlm. 173–183, Nov 2024, doi: 10.33364/algoritma/v.21-2.2134.

[23] W. Lin *dkk.*, "A Deep Neural Collaborative Filtering Based Service Recommendation Method with Multi-Source Data for Smart Cloud-Edge Collaboration Applications," *Tsinghua Sci Technol*, vol. 29, no. 3, hlm. 897–910, Jun 2024, doi: 10.26599/TST.2023.9010050.

[24] V. W. Anelli, A. Bellogín, T. Di Noia, dan C. Pomo, "Reenvisioning the comparison between neural collaborative filtering and matrix factorization," *RecSys 2021 - 15th ACM Conference on Recommender Systems*, hlm. 521–529, Sep 2021, doi: 10.1145/3460231.3475944/SUPPL_FILE/ZOOM_1.MP4.

[25] B. Labibah, R. G. Guntara, dan S. S. Maesaroh, "Kombinasi Inisialisasi Hyperparameter dan Algoritma Adam untuk Optimasi Model Gated Recurrent Unit dalam Meramalkan Harga Penutupan Saham Pasca Isu Boikot," *Building of Informatics, Technology and Science (BITS)*, vol. 6, no. 3, Des 2024, doi: 10.47065/bits.v6i3.6202.

[26] H. Brama, L. Dery, dan T. Grinshpoun, "Evaluation of neural networks defenses and attacks using NDCG and reciprocal rank metrics," *Int J Inf Secur*, vol. 22, no. 2, hlm. 525–540, Apr 2023, doi: 10.1007/S10207-022-00652-0/METRICS.

[27] M. Fröbe, L. Gienapp, M. Potthast, dan M. Hagen, "Bootstrapped nDCG Estimation in the Presence of Unjudged Documents," *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 13980 LNCS, hlm. 313–329, 2023, doi: 10.1007/978-3-031-28244-7_20.

[28] P. J. Chia, J. Tagliabue, F. Bianchi, C. He, dan B. Ko, "Beyond NDCG: Behavioral Testing of Recommender Systems with RecList," *WWW 2022 - Companion Proceedings of the Web Conference 2022*, hlm. 99–104, Agu 2022, doi: 10.1145/3487553.3524215.

[29] I. Schwartz, "Ensemble of MRR and NDCG models for Visual Dialog," *NAACL-HLT 2021 - 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Proceedings of the Conference*, hlm. 3272–3363, 2021, doi: 10.18653/V1/2021.NAACL-MAIN.262.